

Avaliação Semestral GTI5NA – Luana Rodrigues da Silva
RA 74439

Visão Executiva do Projeto

O presente relatório apresenta o projeto executivo consolidado para implantação de um Data Center de Inteligência Artificial de 1 MW no Mercosul, com foco em modelos generativos, soberania de dados, eficiência energética e viabilidade financeira. O projeto considera um orçamento máximo de CapEx de US\$ 10 milhões, conforme diretriz aprovada pelo Board de Diretores.

O cenário proposto posiciona o aluno como Diretor de Infraestrutura e Inteligência Artificial de uma Big Tech, responsável por expandir a capacidade computacional da companhia na região do Mercosul. A solução proposta precisa equilibrar três objetivos estratégicos: rapidez de implantação, eficiência operacional e governança corporativa.

A decisão estratégica deste projeto é implantar o Data Center no Brasil, especificamente na região de Campinas, no estado de São Paulo. A cidade foi escolhida por sua proximidade com São Paulo, presença de ecossistema tecnológico, disponibilidade de fornecedores especializados, conectividade, infraestrutura logística e maturidade operacional para projetos críticos.

O projeto foi estruturado como uma implantação modular. A infraestrutura civil, elétrica, lógica e de refrigeração será desenhada para suportar 1 MW de carga crítica de TI, mas a primeira fase operacional será implantada com 160 kW de carga crítica, composta por um cluster inicial de IA de alto desempenho. Essa decisão permite respeitar o limite de US\$ 10 milhões de CapEx, reduzir risco de execução e manter a expansão futura planejada.

A solução proposta contempla servidores GPU de alta performance, storage NVMe, rede InfiniBand de baixa latência, segurança física e lógica, governança baseada em ISO 27001, SOC2 Type II e TIA-942 Rated 3, além de um plano de Disaster Recovery e Business Continuity.

O projeto não deve ser interpretado apenas como uma obra de infraestrutura, mas como um ativo estratégico para a companhia. Ao internalizar capacidade de processamento de IA, a organização reduz dependência de nuvens públicas, aumenta controle sobre dados sensíveis, melhora previsibilidade de custos e cria uma base escalável para oferta de serviços de IA generativa no Mercosul.

Objetivos, Premissas e Escopo

O objetivo principal do projeto é entregar um plano executivo de implantação de um Data Center de IA de 1 MW, demonstrando viabilidade técnica, regulatória, operacional e financeira. O projeto deve atender às exigências de governança corporativa, segurança da informação e continuidade de negócios, mantendo o CapEx total dentro do limite de US\$ 10 milhões.

Item	Premissa
CapEx máximo	US\$ 10.000.000
CapEx estimado	US\$ 9.567.500
País escolhido	Brasil
Cidade	Campinas/SP
Capacidade final planejada	1 MW de carga crítica
Carga crítica inicial	160 kW
PUE alvo	Inferior a 1.15
Padrão de infraestrutura	TIA-942 Rated 3
Governança	ISO 27001 e SOC2 Type II
Workload principal	IA generativa, LLMs, RAG, fine-tuning e inferência
Modelo de implantação	Modular e escalável
Prazo de implantação	210 dias
Payback estimado	54,2 meses

A implantação será organizada em três grandes dimensões:

- 1. Infraestrutura física e energética;
- 2. Arquitetura tecnológica de IA;
- 3. Governança, segurança e viabilidade financeira.

O escopo contempla o desenho da infraestrutura elétrica, refrigeração, servidores, GPUs, storage, networking, segurança física, segurança lógica, governança de acesso, políticas de proteção de dados, plano de continuidade, matriz de riscos, cronograma de implantação, CapEx, OpEx e análise de payback.

Não faz parte do escopo a construção de uma instalação hyperscale completa com ocupação plena imediata de 1 MW em servidores GPU. Essa abordagem extrapolaria o orçamento aprovado. A proposta tecnicamente mais responsável é criar uma base de Data Center preparada para 1 MW, com implantação inicial controlada e expansão progressiva conforme demanda e monetização da capacidade computacional.

Site Selection: Escolha do Brasil e de Campinas/SP

A escolha do Brasil como país sede do Data Center foi baseada em critérios geopolíticos, energéticos, regulatórios, tecnológicos e econômicos. Entre os países avaliados no Mercosul, o Brasil apresenta a melhor combinação entre mercado consumidor, disponibilidade de fornecedores, infraestrutura de telecomunicações, maturidade regulatória e matriz elétrica com forte participação de fontes renováveis.

A matriz elétrica brasileira é um fator estratégico relevante. A alta participação de fontes renováveis favorece a estratégia ESG do projeto, reduz exposição reputacional e fortalece a defesa de eficiência energética perante o Board. Além disso, o Brasil possui um dos maiores mercados de tecnologia da América Latina, com demanda crescente por aplicações de IA, automação, analytics, atendimento inteligente e modelos generativos.

Campinas/SP foi escolhida por estar localizada em uma das regiões mais desenvolvidas do país em termos de tecnologia, logística e conectividade. A proximidade com São Paulo permite acesso rápido a fornecedores, integradores, telecoms, equipes de manutenção, aeroportos, rodovias e centros de decisão corporativa.

A decisão também considera o aspecto de soberania de dados. Ao manter a infraestrutura em território brasileiro, o projeto fortalece a aderência à LGPD e reduz dependência de processamento em nuvens públicas internacionais. Essa escolha é especialmente relevante para workloads envolvendo dados sensíveis, dados corporativos, dados de clientes e informações estratégicas de negócio.

A análise comparativa dos países foi estruturada da seguinte forma:

País	Pontos fortes	Pontos de atenção	Avaliação
Brasil	Mercado amplo, matriz renovável, fornecedores, conectividade, LGPD	Complexidade tributária e burocracia	Escolhido
Uruguai	Estabilidade institucional e energia limpa	Mercado menor e menor escala operacional	Alternativa forte
Paraguai	Energia hidrelétrica competitiva	Menor ecossistema de tecnologia e conectividade	Não escolhido
Argentina	Mercado relevante	Instabilidade cambial e econômica	Não recomendado

Portanto, o Brasil, e mais especificamente Campinas/SP, oferece o melhor equilíbrio entre eficiência, soberania, segurança, disponibilidade de recursos técnicos e velocidade de implantação.

Estratégia Energética e PUE

A eficiência energética é um dos principais pilares do projeto. O Data Center será projetado para suportar 1 MW de carga crítica de TI, com PUE alvo inferior a 1.15. O PUE, Power Usage Effectiveness, mede a eficiência energética de um Data Center pela relação entre o consumo total da instalação e o consumo dos equipamentos de TI.

A fórmula utilizada é:

$$\text{PUE} = \text{Energia total consumida pelo Data Center} / \text{Energia consumida pelos equipamentos de TI}$$

Para este projeto, a meta é:

$$\text{PUE} < 1.15$$

Isso significa que, para cada 1 kW consumido pelos equipamentos de TI, no máximo 0,15 kW adicional será consumido por refrigeração, UPS, distribuição elétrica, iluminação, segurança e demais sistemas auxiliares.

A capacidade final planejada é de 1 MW de carga crítica. Assim:

$$\text{Carga total do site} = \text{Carga crítica} \times \text{PUE}$$

$$\text{Carga total do site} = 1.000 \text{ kW} \times 1.15$$

$$\text{Carga total do site} = 1.150 \text{ kW}$$

Portanto, a instalação deverá ser capaz de consumir aproximadamente 1,15 MW totais para entregar 1 MW útil aos equipamentos de TI.

Na fase inicial, o projeto considera 160 kW de carga crítica:

$$\text{Carga total inicial} = 160 \text{ kW} \times 1.15$$

$$\text{Carga total inicial} = 184 \text{ kW}$$

Considerando operação 24x7 e 730 horas mensais:

$$\text{Consumo mensal inicial} = 184 \text{ kW} \times 730 \text{ h} / 1.000$$

$$\text{Consumo mensal inicial} = 134,32 \text{ MWh}$$

Na capacidade final:

$$\text{Consumo mensal final} = 1.150 \text{ kW} \times 730 \text{ h} / 1.000$$

$$\text{Consumo mensal final} = 839,5 \text{ MWh}$$

A estratégia energética contempla contrato de energia com alta participação renovável, monitoramento por DCIM/BMS, distribuição elétrica redundante, UPS de alta eficiência, geradores em redundância e medição contínua do consumo por rack, sala e subsistema.

Free Cooling vs. Liquid Cooling

A estratégia de refrigeração é crítica para alcançar PUE inferior a 1.15. O projeto avaliou duas alternativas principais: Free Cooling e Liquid Cooling.

Free Cooling utiliza condições climáticas externas para reduzir o consumo de energia com refrigeração mecânica. Essa estratégia é mais eficiente em regiões de clima frio ou seco, onde a temperatura externa permite resfriamento natural durante boa parte do ano. Em Campinas, essa alternativa pode contribuir parcialmente, mas não deve ser considerada a estratégia principal para um Data Center de IA de alta densidade.

Liquid Cooling utiliza líquido para remover calor diretamente dos componentes de maior densidade térmica, como GPUs e CPUs. Essa tecnologia é mais adequada para clusters de IA generativa, nos quais os servidores podem atingir densidades superiores a 20 kW por rack ou por nó de processamento. Como o projeto utiliza servidores com GPUs NVIDIA H200, a refrigeração líquida se torna a alternativa tecnicamente mais coerente.

Comparativo:

Critério	Free Cooling	Liquid Cooling
Eficiência em Campinas	Moderada	Alta
Aplicação em IA generativa	Limitada	Muito adequada
Densidade suportada	Baixa/média	Alta
Capacidade de atingir PUE < 1.15	Difícil isoladamente	Viável
Complexidade operacional	Menor	Maior
Custo inicial	Menor	Maior
Escalabilidade para GPUs	Limitada	Alta

A decisão técnica é utilizar Liquid Cooling como solução principal, combinado com chillers e dry coolers em configuração redundante. Essa abordagem reduz perdas energéticas, melhora o controle térmico, aumenta a confiabilidade dos servidores GPU e permite expansão futura para densidades maiores.

A arquitetura térmica será composta por:

Componente	Função
CDU — Cooling Distribution Unit	Distribuição e controle do líquido refrigerante
Manifolds	Distribuição do fluido para racks/servidores
Chillers/dry coolers	Rejeição térmica
Sensores de vazão e temperatura	Controle operacional
DCIM/BMS	Monitoramento e alarmística
Redundância N+1	Continuidade em caso de falha

Infraestrutura Civil e Elétrica Básica

O Data Center será implantado em modelo modular, com infraestrutura preparada para expansão até 1 MW de carga crítica. O desenho civil considera áreas funcionais separadas, controle de acesso por zonas, segurança física, operação 24x7 e manutenção concorrente.

As principais áreas previstas são:

Área	Função
Sala de TI	Instalação dos racks de servidores, storage e rede
Sala elétrica	UPS, quadros, distribuição e proteção
Área de geradores	Continuidade de energia em contingência
Área de refrigeração	CDUs, chillers, dry coolers e bombas
Meet-me-room	Entrada de telecomunicações e carriers
NOC	Monitoramento operacional 24x7
Sala de segurança	CFTV, controle de acesso e registros
Área de staging	Recebimento e preparação de equipamentos
Administração	Engenharia, governança e operação

A infraestrutura elétrica foi dimensionada para suportar 1 MW de carga crítica, com redundância suficiente para manutenção concorrente. O padrão recomendado é TIA-942 Rated 3, pois oferece alta disponibilidade e manutenção sem parada total da operação, mantendo o projeto financeiramente viável dentro do limite de CapEx.

Principais componentes elétricos:

Equipamento	Fabricante	Modelo / especificação	Quantidade	Valor estimado
UPS	Vertiv	Liebert EXL S1 1000 kW	1	US\$ 550.000
Baterias	Vertiv	Lithium-ion battery cabinets	1 conjunto	US\$ 210.000
Geradores	Caterpillar	750 kVA	2	US\$ 380.000
Switchgear	Schneider/Siemens	Média/baixa tensão, ATS, busway	1 conjunto	US\$ 650.000
Racks e PDUs	Schneider/APC	NetShelter + PDUs inteligentes	15	US\$ 142.500

A solução contempla alimentação redundante, proteção contra falhas, autonomia por UPS para transição até entrada dos geradores e distribuição elétrica monitorada por rack. A escolha de equipamentos reconhecidos no mercado reduz risco operacional e facilita manutenção, suporte e reposição de peças.

Fundação Estratégica e Viabilidade Energética

A fase AC2 representa o primeiro Board de evolução do projeto, com foco em planejamento estratégico, localização, infraestrutura física, energia e refrigeração.

Nesta fase, a decisão principal foi escolher o Brasil como país sede e Campinas/SP como região de implantação. A decisão foi baseada na combinação entre matriz energética renovável, proximidade com São Paulo, conectividade, fornecedores, segurança jurídica, aderência à LGPD e velocidade de entrada no mercado.

A segunda decisão relevante foi definir a estratégia energética para garantir 1 MW de carga crítica com PUE inferior a 1.15. O projeto concluiu que a meta de eficiência somente seria viável com arquitetura térmica moderna, medição contínua de energia e uso de Liquid Cooling como base para os racks de IA.

A terceira decisão foi adotar infraestrutura modular. Essa escolha mitiga o risco financeiro, pois evita consumir todo o CapEx em uma construção superdimensionada sem ocupação imediata. O Data Center nasce preparado para 1 MW, mas a fase inicial utiliza 160 kW, com expansão conforme demanda, contratos e monetização da capacidade computacional.

Resumo da AC2:

Elemento	Decisão
País	Brasil
Cidade	Campinas/SP
Capacidade final	1 MW de carga crítica
Capacidade inicial	160 kW
PUE alvo	< 1.15
Cooling	Liquid Cooling principal
Infraestrutura	Modular e escalável
Padrão	TIA-942 Rated 3

A evolução da AC2 demonstrou que o projeto possui fundação estratégica sólida e que a escolha de localização, energia e refrigeração está alinhada aos objetivos do Board.

Arquitetura Geral de TI

A arquitetura de TI foi desenhada para suportar workloads de IA generativa, incluindo treinamento, fine-tuning, inferência, RAG, processamento de embeddings, análise de documentos e serviços corporativos de modelos de linguagem.

A arquitetura será composta por cinco camadas principais:

1. Camada de processamento GPU;
2. Camada de storage de alta performance;
3. Camada de rede de baixa latência;
4. Camada de segurança e governança;
5. Camada de operação, observabilidade e continuidade.

Visão conceitual da arquitetura:

Usuários e aplicações

→ API Gateway / Load Balancer

→ Firewall / Segmentação

→ Cluster de IA

→ Storage NVMe / Backup

→ Monitoramento / SIEM / DCIM

→ DR / Cloud de contingência

A camada de processamento é composta por servidores Supermicro SYS-821GE-TNHR com NVIDIA HGX H200 8-GPU. Cada servidor suporta 8 GPUs NVIDIA H200, totalizando 40 GPUs na fase inicial.

A camada de rede de alta performance utiliza switches NVIDIA Quantum-2 QM9700 com InfiniBand NDR 400 Gb/s. Essa rede será utilizada para comunicação entre servidores GPU e storage, reduzindo latência e gargalos em workloads distribuídos.

A camada de storage contempla solução Dell PowerScale all-NVMe para datasets, modelos, checkpoints e arquivos de alta demanda. Para backup e retenção, o projeto considera Dell PowerProtect ou solução equivalente.

A segurança lógica será implementada com firewalls em alta disponibilidade, segmentação de rede, MFA, RBAC, PAM, SIEM e criptografia. A operação será monitorada por DCIM/BMS para energia, refrigeração, rack, temperatura, umidade e alarmes físicos.

Cluster GPU e Hardware de Próxima Geração

O coração tecnológico do projeto é o cluster de IA baseado em GPUs NVIDIA H200. A decisão foi orientada por performance, disponibilidade comercial, eficiência energética e aderência a workloads de IA generativa.

Servidor escolhido:

Item	Especificação
Fabricante	Supermicro
Modelo	SYS-821GE-TNHR
Formato	8U GPU SuperServer
GPUs suportadas	NVIDIA HGX H100/H200 8-GPU
Processadores	Intel Xeon Scalable 4ª/5ª geração
Memória RAM	Até 8 TB DDR5 ECC
Aplicações	AI Training, Deep Learning, HPC, Generative AI

GPU escolhida:

Item	Especificação
Fabricante	NVIDIA
Modelo	H200 SXM
Memória	141 GB HBM3e
Largura de banda	4,8 TB/s
Arquitetura	Hopper
Aplicação	LLMs, IA generativa, HPC e inferência

Configuração inicial:

Item	Quantidade
Servidores GPU	5
GPUs por servidor	8
Total de GPUs	40
Potência estimada por servidor	20 kW
Potência dos servidores GPU	100 kW
Carga adicional de rede/storage/segurança	60 kW
Carga crítica inicial total	160 kW

A escolha da NVIDIA H200 se justifica pela alta capacidade de memória, largura de banda e aderência a modelos generativos. O volume de memória de 141 GB por GPU permite processar modelos maiores, reduzir gargalos de transferência e melhorar eficiência em inferência e fine-tuning.

Storage, Backup e Gestão de Dados

A camada de storage foi desenhada para suportar três tipos principais de dados:

- 1. Datasets utilizados em treinamento e fine-tuning;
- 2. Checkpoints e artefatos de modelos;
- 3. Bases vetoriais, documentos e embeddings utilizados em arquiteturas RAG.

O storage principal será baseado em solução all-NVMe, com alta capacidade de leitura e gravação, baixa latência e escalabilidade. A escolha recomendada é Dell PowerScale F710 ou solução equivalente da mesma categoria.

Arquitetura de storage:

Camada	Fabricante	Modelo estimado	Função	Valor estimado
Storage principal	Dell Technologies	PowerScale F710 all-NVMe	Datasets, modelos e checkpoints	US\$ 400.000
Backup	Dell Technologies	PowerProtect DD9900 equivalente	Backup e retenção	US\$ 180.000
Storage local	Samsung/Kioxia/Intel	NVMe PCIe 4.0/5.0	Cache e staging	Incluso nos servidores

A estratégia de dados será orientada por classificação de informação. Dados sensíveis, dados pessoais, dados estratégicos e dados públicos terão políticas distintas de acesso, retenção, criptografia e auditoria.

Políticas de dados:

Tipo de dado	Política
Dados pessoais	Tratamento conforme LGPD
Datasets sensíveis	Criptografia e acesso restrito
Modelos treinados	Versionamento e controle de integridade
Logs	Retenção e imutabilidade
Backups	Criptografados e testados
Dados temporários	Política de expurgo automático

A camada de backup será integrada ao plano de DR e BCP, com testes periódicos de restauração e replicação de dados críticos para ambiente externo.

Networking de Baixa Latência

A rede é um componente crítico para workloads de IA. Modelos generativos executados em múltiplas GPUs exigem comunicação de alta largura de banda e baixa latência entre servidores, GPUs e storage.

A solução proposta utiliza NVIDIA Quantum-2 QM9700 com InfiniBand NDR 400 Gb/s na camada de IA. Essa rede será dedicada ao tráfego de treinamento, sincronização, comunicação GPU-GPU e acesso de alta performance ao storage.

Componentes de rede:

Camada	Fabricante	Modelo	Função	Valor estimado
Rede IA	NVIDIA	Quantum-2 QM9700	InfiniBand 400 Gb/s	US\$ 380.000
Cabos/adaptadores	NVIDIA/Mellanox	OSFP/DAC/ópticos 400G	Interconexão	US\$ 150.000
Rede Ethernet	Arista	100/400GbE	Serviços corporativos	US\$ 180.000
Rede OOB	Arista/Cisco	10/25GbE	Gerenciamento	Incluso no pacote

A topologia lógica recomendada é Spine-Leaf, permitindo baixa latência, escalabilidade e redundância. A rede de IA será segregada da rede corporativa e da rede de gerenciamento, reduzindo risco de interferência, ataques laterais e congestionamento.

Topologia conceitual:

Aplicações / APIs

- Firewalls HA
- Rede Ethernet corporativa
- Cluster de inferência / serviços
- Rede InfiniBand IA
- Servidores GPU
- Storage NVMe

A segmentação será complementada por VLANs, ACLs, firewalls internos e políticas Zero Trust.

Segurança Física, Segurança Lógica e Soberania de Dados

A segurança do Data Center será desenhada em camadas. O objetivo é proteger a infraestrutura física, os dados, os modelos, as credenciais, a rede e a operação.

Segurança física:

Controle	Descrição
Perímetro	Controle de acesso ao prédio
CFTV	Monitoramento contínuo
Biometria	Acesso a áreas críticas
Crachá	Identificação individual
Registro de visitantes	Entrada controlada e auditável
Zonas de segurança	Separação entre áreas administrativas, técnicas e críticas
Sala de TI	Acesso restrito e monitorado

Segurança lógica:

Controle	Descrição
MFA	Autenticação multifator
RBAC	Controle por função
PAM	Gestão de acesso privilegiado
SIEM	Correlação de eventos
Criptografia	Dados em repouso e em trânsito
Segmentação	Separação de redes e ambientes
Logs imutáveis	Evidência para auditoria
DLP	Prevenção contra vazamento de dados

A soberania de dados será garantida pela manutenção dos dados em território brasileiro, com aderência à LGPD e políticas específicas para dados sensíveis. Dados usados para treinamento e fine-tuning terão trilha de origem, classificação, autorização de uso e retenção documentada.

A segurança também contempla proteção dos modelos. Modelos treinados serão tratados como ativos estratégicos, com versionamento, assinatura, controle de acesso e monitoramento contra cópia indevida ou uso não autorizado.

Framework de Governança e Conformidade

O projeto foi desenhado para atender três padrões principais exigidos pelo Board:

- 1. ISO 27001;
- 2. SOC2 Type II;
- 3. TIA-942 Rated 3.

A ISO 27001 será utilizada como base para o Sistema de Gestão de Segurança da Informação. Ela orienta a definição de políticas, gestão de riscos, controles de segurança, responsabilidades, auditorias e melhoria contínua.

O SOC2 Type II será utilizado para demonstrar a efetividade dos controles ao longo do tempo, especialmente nas dimensões de segurança, disponibilidade, confidencialidade e privacidade.

A TIA-942 Rated 3 será utilizada como referência de infraestrutura de Data Center com manutenção concorrente, redundância e disponibilidade adequada para operação crítica.

Mapeamento de controles:

Framework	Controle aplicado
ISO 27001	Gestão de riscos, políticas de segurança, auditoria e controle de acesso
SOC2 Type II	Evidências operacionais, disponibilidade, confidencialidade e resposta a incidentes
TIA-942 Rated 3	Redundância, manutenção concorrente e disponibilidade física
LGPD	Proteção de dados pessoais e soberania regional
Zero Trust	Acesso mínimo necessário
RBAC	Acesso por função
PAM	Controle de contas privilegiadas
SIEM	Monitoramento e resposta

A governança será suportada por um comitê de segurança e infraestrutura, composto por representantes de TI, Segurança da Informação, Jurídico, Compliance, Operações e Negócios.

Esse comitê será responsável por revisar riscos, aprovar mudanças críticas, acompanhar auditorias, avaliar incidentes, monitorar indicadores e garantir alinhamento contínuo com os objetivos corporativos.

Tech Stack, Governança, DR e BCP

A fase AC3 representa o segundo Board de evolução do projeto. O foco foi consolidar a arquitetura de TI, selecionar os componentes de hardware de próxima geração, definir a governança e estruturar os planos de Disaster Recovery e Business Continuity.

A principal decisão técnica da AC3 foi a adoção de um cluster inicial com 5 servidores Supermicro SYS-821GE-TNHR, cada um com 8 GPUs NVIDIA H200. Essa escolha equilibra alta performance, disponibilidade comercial e aderência ao orçamento.

A segunda decisão foi a adoção de rede InfiniBand NVIDIA Quantum-2 QM9700, com 400 Gb/s, garantindo baixa latência para comunicação entre nós de IA.

A terceira decisão foi a definição de storage all-NVMe, com Dell PowerScale ou equivalente, complementado por solução de backup Dell PowerProtect ou equivalente.

A quarta decisão foi a construção do framework de governança com base em ISO 27001, SOC2 Type II e TIA-942 Rated 3.

Plano de DR e BCP:

Item	Definição
RTO	4 horas para serviços críticos
RPO	15 minutos para metadados e sistemas de controle
Backup	Diário incremental e semanal completo
Replicação	Ambiente externo/cloud para dados críticos
Teste de restore	Mensal
Teste de DR	Semestral
Energia	UPS + geradores
Rede	Dois carriers independentes
Operação	NOC 24x7

A AC3 demonstrou que o projeto não se limita à aquisição de equipamentos. Ele estabelece uma arquitetura governada, segura, auditável e resiliente.

CapEx Detalhado

O CapEx foi estruturado para respeitar o limite de US\$ 10 milhões aprovado pelo Board. O investimento total estimado é de US\$ 9.567.500, mantendo reserva de contingência para variação cambial, importação, frete, impostos e ajustes de escopo.

Tabela de CapEx:

Categoria	Fabricante	Modelo / especificação	Qtd	Total US\$
GPU Compute	Supermicro	SYS-821GE-TNHR HGX H200 8-GPU	5	3.375.000
Storage principal	Dell	PowerScale F710 all-NVMe	1	400.000
Storage backup	Dell	PowerProtect DD9900 equivalente	1	180.000
Rede IA	NVIDIA	Quantum-2 QM9700 400 Gb/s	4	380.000
Cabos/adaptadores	NVIDIA/Mellanox	OSFP/DAC/ópticos 400G	1	150.000
Rede Ethernet/OOB	Arista	100/400GbE + gestão	1	180.000
Firewalls	Palo Alto	PA-5450 + subscriptions	2	180.000
Racks/PDUs	Schneider/APC	NetShelter + PDUs inteligentes	15	142.500
UPS	Vertiv	Liebert EXL S1 1000 kW	1	550.000
Baterias	Vertiv	Lithium-ion cabinets	1	210.000
Geradores	Caterpillar	750 kVA	2	380.000
Distribuição elétrica	Schneider/Siemens	Switchgear, transformador, busway	1	650.000
Cooling líquido	Vertiv/CoolIT	CDU + manifolds	1	720.000
Chillers/dry coolers	Vertiv/Trane	Rejeição térmica N+1	1	420.000
DCIM/BMS	Schneider/Vertiv	EcoStruxure/Trellis	1	120.000
Segurança física	Axis/HID/LenelS2	CFTV, acesso, biometria	1	120.000
Obra civil/modular	EPC local	Adequação civil e técnica	1	650.000
Certificações	Consultoria	ISO 27001, SOC2, TIA-942	1	90.000
Implantação	Integrador	Instalação, testes e burn-in	1	320.000
Contingência	Reserva	Risco cambial/RFQ/importação	1	350.000

Total estimado: **US\$ 9.567.500**

A alocação do CapEx demonstra que a maior parte do investimento está concentrada no cluster GPU, infraestrutura elétrica, refrigeração e rede de alta performance. Essa distribuição é coerente com um Data Center voltado para IA generativa.

OpEx, Energia e Cálculos Financeiros

O OpEx mensal inicial foi estimado considerando energia, equipe, manutenção, conectividade, facilities, seguros, licenças e segurança.

Tabela de OpEx mensal:

Item	Valor mensal estimado
Energia fase inicial	US\$ 10.923
Equipe 24x7	US\$ 42.000
Manutenção HW/SW	US\$ 58.000
Conectividade/carriers	US\$ 22.000
Facilities/seguros	US\$ 18.000
Licenças/DCIM/segurança	US\$ 16.000

OpEx mensal inicial: US\$ 166.923

OpEx anual inicial: US\$ 2.003.076

Cálculo de energia da fase inicial:

Carga crítica inicial = 160 kW

PUE = 1.15

Carga total = $160 \times 1.15 = 184$ kW

Horas mensais = 730 h

Consumo mensal = $184 \times 730 / 1.000 = 134,32$ MWh

Cálculo de energia na capacidade final:

Carga crítica final = 1.000 kW

PUE = 1.15

Carga total = $1.000 \times 1.15 = 1.150$ kW

Consumo mensal = $1.150 \times 730 / 1.000 = 839,5$ MWh

O custo de energia representa uma parcela relevante do OpEx, mas a utilização de PUE inferior a 1.15, Liquid Cooling e contratação de energia renovável reduzem impacto financeiro e aumentam previsibilidade operacional.

Cronograma, Payback e Business Case

A fase AC4 representa o terceiro Board de evolução do projeto. O objetivo foi consolidar cronograma, CapEx, OpEx, payback e comparação com nuvem pública.

Roadmap de implantação:

Fase	Período	Entregável
0. Business Case	D0-D15	Aprovação CapEx, matriz de decisão e RFQ
1. Site & Energia	D16-D45	Contrato do site, estudo de energia e licenças
2. Engenharia Detalhada	D46-D75	Projeto civil, elétrico, cooling e segurança
3. Compras Críticas	D46-D120	Servidores, UPS, storage, rede e cooling
4. Obra & Infraestrutura	D76-D150	Sala de TI, elétrica, racks, refrigeração
5. Instalação de TI	D121-D165	Cluster GPU, storage, rede e firewalls
6. Governança	D121-D180	Políticas, controles, DR, BCP e compliance
7. Testes & Go-live	D166-D210	Burn-in, teste de carga, failover e operação assistida

Go-live estimado: 210 dias.

Premissas do payback:

Item	Valor
CapEx	US\$ 9.567.500
GPUs H200	40
Utilização média	70%
Horas mensais	730
GPU-horas disponíveis/mês	29.200
GPU-horas utilizadas/mês	20.440
Valor cloud equivalente	US\$ 8/GPU-h
Custo cloud evitado	US\$ 163.520/mês
Receita incremental IA	US\$ 180.000/mês
Valor econômico mensal bruto	US\$ 343.520
OpEx mensal	US\$ 166.923
Margem econômica mensal	US\$ 176.597

Cálculo do payback:

$\text{Payback} = \text{CapEx} / \text{Margem econômica mensal}$

$\text{Payback} = 9.567.500 / 176.597$

$\text{Payback} = 54,2 \text{ meses}$

A interpretação executiva é que o projeto se paga em aproximadamente 4,5 anos no cenário base. Esse retorno melhora conforme a ocupação da infraestrutura aumenta e novos servidores são adicionados ao ambiente já preparado para 1 MW.

Matriz de Riscos


A matriz de riscos contempla riscos geopolíticos, operacionais, tecnológicos, financeiros, regulatórios e de cadeia de suprimentos.

Risco	Categoria	Probabilidade	Impacto	Mitigação
Variação cambial	Financeiro	Alta	Alto	Reserva de contingência, negociação em dólar e hedge
Atraso na entrega de GPUs	Cadeia de suprimentos	Alta	Alto	RFQ antecipado e fornecedores alternativos
CapEx insuficiente para ocupação plena	Financeiro	Alta	Alto	Implantação modular e expansão por fases
PUE acima da meta	Operacional	Média	Alto	Liquid Cooling, DCIM e comissionamento térmico
Falha de energia	Operacional	Média	Alto	UPS, baterias e geradores
Falha de refrigeração	Operacional	Média	Alto	CDUs e chillers em redundância
Risco de segurança cibernética	Segurança	Alta	Alto	Zero Trust, SIEM, MFA, PAM e segmentação
Não conformidade regulatória	Governança	Média	Alto	ISO 27001, SOC2, LGPD e auditorias
Dependência de fornecedor	Estratégico	Média	Médio	Contratos com SLA e alternativas técnicas
Baixa ocupação do cluster	Comercial	Média	Alto	Monetização da capacidade e contratos âncora
Atraso em licenças/obra	Projeto	Média	Médio	Planejamento prévio e gestão de fornecedores
Falha de backup/DR	Continuidade	Baixa	Alto	Testes mensais de restore e testes semestrais de DR


A matriz demonstra que os principais riscos do projeto estão ligados a fornecimento de hardware, variação cambial, ocupação da capacidade e eficiência energética. A mitigação mais importante é a implantação modular, que reduz exposição financeira e permite expansão progressiva.

Arquitetura, Infraestrutura e Governança do Data Center de IA – 1 MW


Arquitetura Geral de TI




Infraestrutura Elétrica Tier III



Arquitetura de Refrigeração Líquida



Roadmap de Implementação



Lições Aprendidas e Conclusão

Acredito que os conceitos e aprendizados adquiridos ao longo deste projeto foram extremamente enriquecedores, não apenas para minha vida acadêmica, mas também para meu desenvolvimento profissional e pessoal. Durante a elaboração do trabalho, foi possível desenvolver uma visão mais estratégica sobre gestão, governança, infraestrutura e tomada de decisões em projetos de tecnologia.

Do meu ponto de vista pessoal, e sendo totalmente sincera, reconheço que tive recursos e oportunidades para me aprofundar mais na disciplina e nos conteúdos abordados ao longo do semestre, mas em muitos momentos não aproveitei esse potencial da forma que poderia. Por esse motivo, não consegui apresentar durante as atividades tudo o que havia planejado inicialmente, principalmente pela falta de aprofundamento técnico em alguns temas.

Como este é o último semestre da graduação, percebo claramente a evolução da minha visão sobre o que é um Data Center e sobre a complexidade envolvida na construção e gestão de um projeto dessa magnitude. Comparando o conhecimento que possuía no início da disciplina com o que tenho hoje, considero que houve um amadurecimento significativo. Ainda assim, reconheço que poderia ter me aprofundado mais e alcançado um resultado ainda melhor.

Em relação à pergunta final, se eu tivesse hoje USD 10.000.000 disponíveis para investimento, acredito que investiria neste projeto. A elaboração deste trabalho exigiu pesquisas, análises técnicas, avaliação de riscos e planejamento financeiro detalhado, fatores que contribuíram para a construção de uma proposta sólida e bem fundamentada. Embora projetos dessa natureza envolvam riscos consideráveis, procurei identificar e mitigar os principais fatores que poderiam gerar prejuízos ou comprometer a operação.

Naturalmente, todo investimento possui riscos, especialmente em um setor que evolui de forma tão rápida quanto a tecnologia e a inteligência artificial. No entanto, também acredito que inovação exige coragem para assumir desafios calculados. Dessa forma, considerando os estudos realizados e as estratégias de mitigação apresentadas, eu investiria no projeto, mantendo uma abordagem cautelosa, porém confiante em seu potencial de crescimento e retorno a longo prazo.